Unidad 3. Relevancia semántica y coincidencia de palabras

Franco Castro · AI Engineering · Ejercicio opcional

Qué se evalúa

Un buscador por palabras cuenta cuántas palabras se repiten. Un buscador semántico convierte cada texto en un vector (un embedding) y mide el ángulo entre vectores. Dos frases pueden hablar de lo mismo sin compartir vocabulario. Dos frases pueden compartir palabras y querer decir otra cosa.

El concepto elegido es el despliegue de microservicios: publicar en producción un sistema hecho de partes independientes. La consulta de referencia es: «¿Cómo se publican las partes independientes de un sistema para que atiendan tráfico real?»

Cinco oraciones del mismo concepto

Dicen lo mismo. Ninguna usa las palabras «microservicio», «despliegue» ni «producción».

	Oración	Cómo lo dice
1	Cada pieza autónoma del sistema se libera en el clúster y empieza a atender tráfico.	«liberar en el clúster» es publicar. «pieza autónoma» es el servicio.
2	Los módulos desacoplados quedan operativos mediante contenedores.	«quedan operativos» es el momento en que ya están arriba. El contenedor es el vehículo.
3	El pase a vivo de los componentes aislados se hace detrás del balanceador de carga.	«pase a vivo» es el release. El balanceador es la puerta por donde entran los pedidos.
4	Las partes independientes de la arquitectura se activan para que los clientes las consuman.	Mismo hecho, dicho desde quien usa el sistema.
5	La puesta en marcha de las unidades separadas ya está hecha y responden peticiones reales.	«puesta en marcha» reemplaza a «despliegue». «peticiones reales» reemplaza a «producción».

Un buscador por palabras, frente a la consulta, deja estas cinco casi en cero: no hay términos en común. Un embedding las acerca, porque el tema es uno solo.

Dos oraciones trampa

	Oración	Por qué es trampa
6	El servicio de micro-limpieza del edificio es excelente.	Comparte «servicio» y el prefijo «micro». El tema es limpieza, no software. Es irrelevante.
7	No hay despliegue de microservicios: el monolito sigue intacto y no se publica nada.	Comparte «despliegue» y «microservicios», pero el sentido es el contrario: no se hace.

La trampa 6 engaña a un buscador por palabras sueltas y debería quedar lejos en un espacio de embeddings: el tema no es el mismo.

La trampa 7 es la más difícil. Por palabras clave saldría primera, porque repite los términos de la consulta. Por significado no sirve como respuesta: dice que el despliegue no ocurre. Los embeddings suelen acercar igual los textos del mismo tema, y la negación («no hay») pesa menos que el tema. Esa es la limitación que hay que conocer: la similitud coseno mide cercanía de tema, no detecta sola un «no».

Similitud coseno con scikit-learn

La similitud coseno es el coseno del ángulo entre dos vectores. Va de −1 a 1. Cerca de 1, apuntan al mismo lado. Cerca de 0, no tienen relación. No mira si las palabras coinciden: mira la dirección de los números.

La cuenta es el producto punto dividido por el producto de las longitudes. `sklearn.metrics.pairwise.cosine_similarity` hace esa cuenta. Recibe matrices de forma `(cantidad, dimensiones)` y devuelve una matriz de puntajes. Los vectores de abajo son un ejemplo para ver el número. No son los embeddings de las oraciones de arriba.

```
from sklearn.metrics.pairwise import cosine_similarity

consulta = [[0.80, 0.10, 0.05]]
oracion_parecida = [[0.76, 0.18, 0.08]]
trampa = [[0.05, 0.90, 0.10]]

parecida = cosine_similarity(consulta, oracion_parecida)[0][0]
irrelevante = cosine_similarity(consulta, trampa)[0][0]

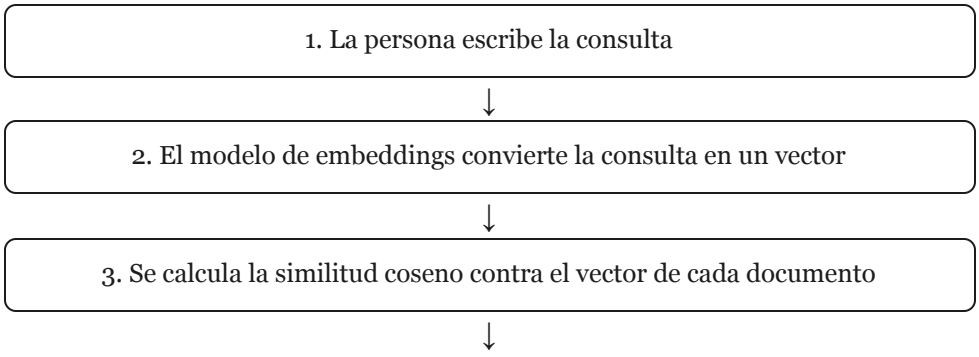
print(f"consulta vs oración del mismo tema: {parecida:.3f}")
print(f"consulta vs trampa de palabras:     {irrelevante:.3f}")
```

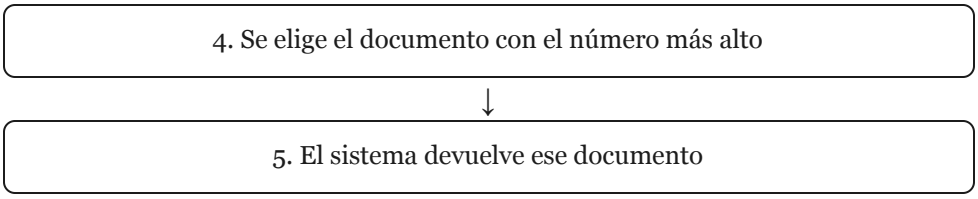
Resultado de esa corrida: la oración del mismo tema da **0.993**. La trampa da **0.184**. El número alto es el texto que se devuelve.

El archivo `unidad_3/ejercicio_opcional/similitud.py` es ese fragmento. Se corre, con el entorno activo, desde la raíz del repo: `python unidad_3/ejercicio_opcional/similitud.py`.

Búsqueda semántica

Desde que la persona escribe hasta que vuelve un documento. Los vectores de los documentos se calculan antes y quedan guardados. En la consulta solo se embebe la pregunta y se compara.





Conclusión

Las oraciones 1 a 5 sobrevivirían a un ranking semántico y desaparecerían en uno por palabras. La 6 al revés: las palabras alcanzan para colarse y el significado no. La 7 muestra el límite: compartir el tema, incluso para negarlo, deja los vectores cerca. La similitud coseno ordena por dirección. No entiende sola la intención de la frase.